Siamese ResNeXt ile Islak İmza Sahtekârlığı Tespiti
Wet-Ink Signature Forgery Detection Using Siamese ResNeXt

2024 32nd Signal Processing and Communications Applications Conference (SIU) | 979-8-3503-8896-1/24/$31.00 ©2024 IEEE | DOI: 10.1109/SIU61531.2024.10600997

Serkan Can Çağlayan
SmartIR
sccaglayan@smartir.io

Şevval Uyanık
SmartIR
suyanik@smartir.io

Nurullah Çalık
İstanbul Medeniyet Üniversitesi
nurullah.calik@medeniyet.edu.tr

***Özetçe* —Islak imzalı belgelerde meydana gelen imza sahtekârlığı, bireyin imzasının izni olmaksızın başka bir kişi tarafından taklit edilmesi durumunu ifade eder. Bu tür sahtekârlık, önemli belgelerin güvenilirliğini tehdit eden ciddi bir sorundur. Bu çalışmada, ıslak imzalı belgelerdeki imza sahtekârlığı sorununa çözüm olarak Siamese ağları kullanılmıştır. Siamese ağları, öğrenme sürecinde benzer ve farklı sınıflara ait imza çiftlerini karşılaştırma yeteneği sayesinde imza sahtekârlığı tespitinde etkili bir araç olarak kullanılmıştır. Siamese ağlarına girdi olarak imza görüntülerinin yanı sıra, imza görüntülerinin frekans spektrumları ve HOG(Histogram of Oriented Gradients) öznitelikleri kullanılmıştır. Siamese ResNeXt-50 tarafından üretilen öznitelik vektörleri birleştirilmiş ve doğrusal bir katman kullanılarak sınıflandırma gerçekleştirilmiştir. İkili sınıflama problemine uygun olarak kayıp fonksiyonu için İkili Çapraz Entropi(Binary Cross Entropy Loss) tercih edilmiştir. Bu yöntem, çeşitli veri setleri üzerinde derinlemesine analiz edilmiş ve yapay zeka, imza sahtekârlığı problemine karşı etkili bir çözüm sunmuştur. Sonuçlar, Siamese ağlarının imza sahtekârlığı tespiti konusunda başarılı bir şekilde kullanılabileceğini göstermekle birlikte imza sahtekârlığına karşı güvenilir ve etkili bir çözüm sunma potansiyelini vurgulamaktadır.**

Anahtar Kelimeler*—*Islak imza, imza sahtekarlığı, ikili sınıflama, derin öğrenme, siamese ağlar.

***Abstract*—In cases of wet-signed documents, signature forgery refers to the unauthorized imitation of an individual's signature by another person without their consent, posing a serious threat to the reliability of important documents. In this study, Siamese networks have been employed as a solution to address the issue of signature forgery in wet-signed documents. Siamese networks prove to be effective tools in detecting signature forgery due to their capability to compare signature pairs belonging to similar and different classes during the learning process. As inputs to the Siamese networks, not only signature images but also the frequency spectra and Histogram of Oriented Gradients (HOG) features of these images have been utilized. Feature vectors generated by Siamese ResNeXt-50 are combined, and linear layers are employed for classification. Binary Cross Entropy Loss has been chosen as the loss function, in accordance with the binary classification problem. The results indicate the successful application of Siamese networks in detecting signature forgery, emphasizing their potential to offer a reliable and effective solution to counter signature forgery.**

Keywords*—*Wet ink signature, signature forgery, binary classification, deep learning, siamese networks.

979-8-3503-8896-1/24/$31.00 ©2024 IEEE

I. GİRİŞ

Biyometrik çalışmalar, günümüzde hızla ivme kazanmaktadır. Özellikle biyometrik verilerin çeşitliliği ve değerlendirme yöntemlerindeki yenilikler, bu alandaki önemli gelişmeleri tetiklemiştir. Geleneksel biyometrik kimlik doğrulama yöntemleri, yüz tanıma, parmak izi ve el damarları gibi sabit ölçümlere dayanmaktaydı. Ancak, artık bu yöntemler, kişiye özgü ve dinamik bilgileri içeren biyometrik verilerle değişim göstermektedir. Bu değişimin ardında yatan temel nedenlerden biri, statik biyometrik verilerin kopyalanması veya sahteciliğe karşı korunmasının zorluğudur. Bu nedenle,hareket bilgisine dayalı biyometrik kimlik doğrulama yöntemleri daha fazla tercih edilmektedir. Doğrulama süreci genellikle çevrimiçi ve çevrimdışı olarak iki ana kategoriye ayrılmaktadır. Çevrimiçi sistemlerde, imza yazma sürecindeki dinamik bilgiler kaydedilirken, çevrimdışı sistemlerde imza görüntüleri dijital cihazlar tarafından yakalanır. Çevrimiçi yöntemde, imzanın dinamik özellikleri dikkate alınırken, çevrimdışı imza doğrulamada sadece statik özellikler mevcuttur. Bankacılık işlemleri ve belge doğrulama uygulamaları genellikle çevrimdışı imza doğrulama gerektirir.

Aynı kişinin farklı zamanlarda veya durumlarda verdiği imzaların farklılık gösterebilmesi, kişinin ruh haline ve fiziksel durumuna bağlı olarak değişebilmesi imza tanıma sistemlerinin karşılaştığı önemli bir zorluktur. Bu zorluklar, literatürdeki çalışmaları da belirgin hale getirmiştir. Büyük veri kümeleriyle yapılan çalışmalarda, geleneksel yöntemlerin yetersiz kalabileceği görülmektedir. Bu durum, derin öğrenme yöntemlerinin, özellikle büyük veri setleri için önemli bir araştırma alanı haline gelmesine neden olmaktadır.

İmza tanıma sistemleri genellikle dört alt görevi içerir: giriş görüntüsünün ön işlenmesi, görüntünün özelliklerinin çıkarılması, tanıma ve sınıflandırıcı kullanarak doğrulama. Ön işleme algoritması, özellik çıkarımı için işlenmiş veri sağlar. Özellik çıkarımı, giriş ham verisinin belirli özelliklerinin çıkarılması olarak tanımlanır ve daha sonra sınıflandırma aşamasında kullanılır. Tanıma aşaması, sinir ağı modelinin eğitilmesi ve test edilmesi olarak iki bölüme ayrılır.

Literatürde birçok çalışma bulunmaktadır ve bu çalışmalardaki yöntemler genellikle özellik çıkarımı ve sinir ağı kullanımı gibi ortak temellere dayanır. [1]'deki çalışmada imza doğrulama için konvolüsyonel sinir ağlarını (CNN) kullanarak imza görüntülerinden özellik öğrenmeye yönelik yeni bir yaklaşım sunmaktadır. Kullanılan CNN mimarisi sıralı ve basit bir

Authorized licensed use limited to: REVA UNIVERSITY. Downloaded on October 09,2026 at 06:57:50 UTC from IEEE Xplore. Restrictions apply.

mimari olmakla birlikte çalışma gerçek imzaları becerikli taklit imzalardan ayırt etme zorluklarından bahsetmiştir. Bir diğer çalışma olan [2]'de ise imzalar için dokusal özelliklere dayalı bir imza doğrulama yöntemini sunulmuştur. Yöntem olarak Yerel ikili örüntüler(Local Binary Patterns) ve Benzer Yerel ikili Örüntüler (Uniform Local Binary Patterns) ile çıkarılan imza özniteliklerini K-En Yakın Komşuluk(K-Nearest Neighbors) sınıflayıcısı ile anlamlandırılmıştır. [3]'de ise iki kanallı bir konvolüsyonel sinir ağı (CNN) kullanılmıştır. Kullanılan ağın aşırı öğrenme problemi ise girdi imzaları arasındaki benzerliği iki logit değeri kullanarak çözülmüştür.

II. Veri Kümesi

Bu çalışmada, imza doğrulama sistemlerinin geliştirilmesi amacıyla oluşturulmuş olan iki farklı veri seti kullanılmıştır. 260 farklı kişinin imzasını içeren ve bu imzaların hem gerçek hem de sahte örnekleri bulunduran BHSig260 veri kümesini kullanılan veri setlerinden ilkidir. Bu veri kümesindeki kişilerin 100'ü Bengal kökenli imzalara sahipken, 160 kişi Hindi kökenli imzalara sahiptir. Toplam veri kümesindeki 6240 gerçek imza ve 7800 nitelikli sahte imza bulunmaktadır. Her bir kişi için, 24 gerçek ve 30 nitelikli sahte imza olmak üzere toplamda 54 imza bulunmaktadır. Bengal kökenli imzalar için toplamda 2400 gerçek imza ve 3000 nitelikli sahte imza bulunmaktadır. Hindi kökenli imzalar için ise toplamda 3840 gerçek imza ve 4800 nitelikli sahte imza bulunmaktadır. Tüm yazarların gerçek ve sahte imzaları eğitim ve test amaçlarıyla kullanılmıştır [4].

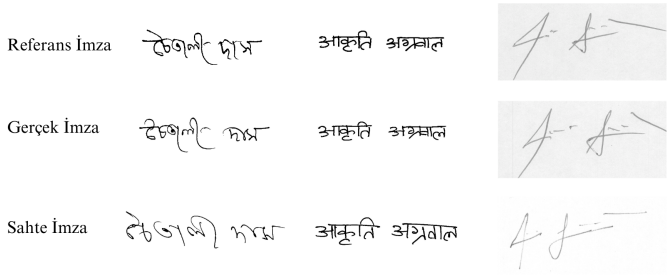
Kullanılan ikinci veri seti olan CEDAR veri kümesi, imza doğrulama amacıyla kullanılan bir veri kümesidir ve 55 farklı kişinin katkılarıyla oluşturulmuştur. Toplamda, her bir kişi 24 gerçek imza sunarak toplam 1,320 gerçek imza sağlamıştır. Ayrıca, bazı kişilerden üç farklı yazarın imzasını taklit etmeleri istenmiş ve her bir kişi bu taklit imzaları için sekiz kez olmak üzere toplamda 1,320 sahte imza oluşturulmuştur. İmzalar, taranırken 300 dpi çözünürlüğe sahip gri tonlamalı görüntüler olarak kaydedilmiştir. İmza veri kümesi oluşturulurken, görüntüler üzerinde gürültüyü temizleme ve eğim normalleştirme gibi ön işleme adımları uygulanmıştır. Bu adımlar, imza özelliklerinin daha net ve karşılaştırılabilir hale gelmesine yardımcı olmaktadır. Her bir yazar için 24 gerçek ve 24 sahte imza bulunmaktadır [5].

TABLO I: Kullanılan Veri Setleri Sınıf Dağılımları

Veri Seti	Özellikler		
	Toplam Örnek	Taklit İmza İkili Sayısı	Gerçek İmza İkili Sayısı
CEDAR	2149	1010	1139
Hindi	8640	4800	3840
Bengali	5400	3000	2400

Üç veri seti de, %75'i eğitim, %25'i doğrulama için kullanılacak şekilde ayrılmıştır. Bu şekilde, modelin eğitim sırasında farklı veri parçalarını kullanarak genelleme yeteneği artırılmış ve doğrulama kümesi aracılığıyla modelin performansı değerlendirilmiştir.

Bu veri kümeleri, imza doğrulama alanında yapılan araştırmalarda önemli bir rol oynamaktadır. Araştırmacılar, bu veri kümelerini kullanarak derin öğrenme, görüntü işleme ve desen tanıma gibi alanlarda yeni teknikler geliştirmekte ve mevcut sistemlerin performansını sürekli olarak iyileştirmektedirler.



Şekil 1: İmza Örnekleri

Yüksek kaliteli ve çeşitli veriye erişim, araştırmacıların algoritmalarını daha sağlam bir şekilde test etmelerini ve günlük hayatta karşılaşılan çeşitli senaryolara uyum sağlamalarını sağlar. Şekil 1' de farklı veri kümelerine ait gerçek ve sahte örnekler görülmektedir. Birinci ve ikinci sütundaki imzalar BHSig260 veri kümesine ait Bengal ve Hindi kökenli örneklerdir. Üçüncü sütundaki imzalar ise CEDAR veri kümesine ait örneklerdir.

III. Metot ve Yöntemler

A. Veri Ön İşlemesi

Bu çalışmada, derin öğrenme modellerinin sadece imza görüntüleri üzerinden tatmin edici başarıma ulaşamadıkları gözlemlenmiştir. Bu sebeple süreç, derin öğrenme modelinin imza görüntülerinden farklı öznitelikler çıkarabilmesine olanak tanıyabilecek şekilde ilerletilmiştir. Siamese ResNeXt-50 yöntem mimarisi Şekil 2 üzerinde detaylı olarak görülmektedir.

İlk adım olarak Şekil 2'te bulunan Img.1A ve Img. 2A'da görüldüğü üzere her imza görüntüsünden imza geleneksel görüntü işleme yöntemleri ile tespit edilip kırpılmıştır. Bu aşama, modelin imzanın kendisine odaklanarak arka plan veçevresel faktörlerden etkilenme, imzanın görüntü içerisindeki konumundan bilgi çıkarma olasılığını azaltmak amacı ile yapılmıştır.

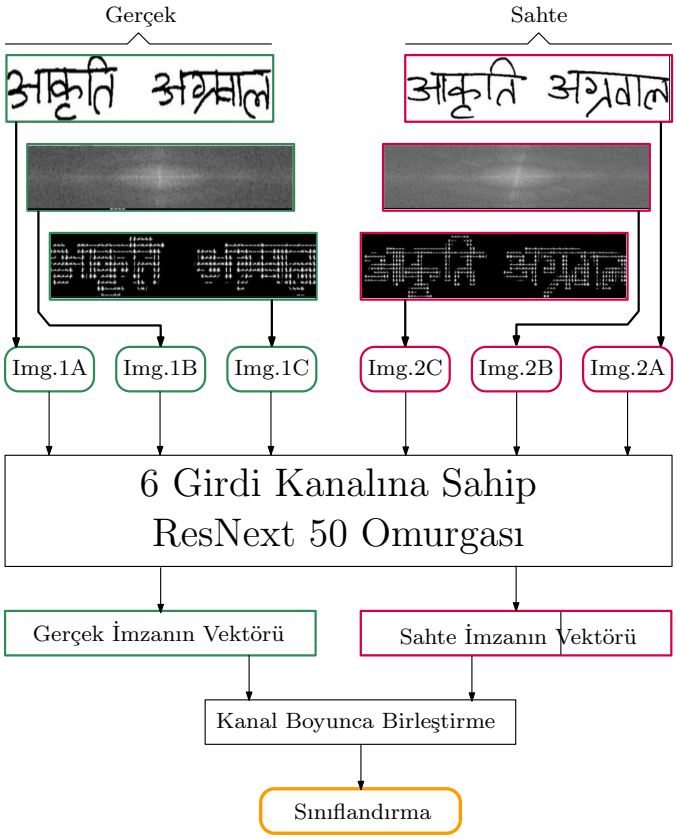
İkinci aşamada her imzanın frekans spektrumu, Hızlı Fourier Dönüşümü (Fast Fourier Transform - FFT) kullanılarak hesaplanmıştır. Bu adım, imzanın frekans bileşenlerini vurgulayarak benzersiz özellikleri ortaya çıkarmıştır. Gerçek ve sahte imzaların frekans spektrumu Şekil 2 üzerindeki Img.1B ve Img. 2B'de görülmektedir. Frekans spektrumu, modelin imzalar arasındaki farklılıkları daha etkili bir şekilde yakalamasına olanak tanıyan bir özellik olarak kullanılmıştır.

Üçüncü aşamada ise her imzanın Yönlü Gradyanlar Histogramı (Histogram of Oriented Gradients - HOG) özellikleri çıkarılmıştır. HOG, görüntülerdeki kenar ve desen bilgilerini temsil etmek için kullanılan bir özellik vektörüdür. HOG özellikleri, imzaların yapısal özelliklerini daha iyi anlamak için modelin kullanımı için eklenen bir başka önemli bileşen olarak belirlenmiştir. Gerçek ve sahte imzaların HOG özellikleri Şekil 2 üzerindeki Img.1C ve Img. 2C'de görülmektedir.

B. Önerilen ResNeXt Tabanlı Siamese Model

Son yıllarda, derin öğrenme alanındaki araştırmaların gelişimi, bilgisayarların daha karmaşık görevleri daha etkili bir şekilde gerçekleştirebilen sinir ağları geliştirmeyi öğrenmesini

Authorized licensed use limited to: REVA UNIVERSITY. Downloaded on October 09,2026 at 06:57:50 UTC from IEEE Xplore. Restrictions apply.



Şekil 2: Siamese ResNeXt-50 Yöntem Mimarisi

sağladı. Bu alandaki önemli bir çalışma, Kaiming He ve ekibinin 2017'de tanıttığı Derin Sinir Ağları için Toplu Artık Dönüşümler (ResNeXt) adlı modeldir. ResNeXt, derin ağların performansını artırmak için geliştirilmiş bir yöntem sunar.

ResNeXt, derin sinir ağlarının temel mimarisi olan Artık Ağlar modelinin bir geliştirilmesidir. Ancak, ResNeXt, ResNet'in temel fikirlerini genişleterek daha fazla esneklik ve ölçeklenebilirlik sağlar. Özetle, ResNeXt, farklı özellikleri daha iyi öğrenebilen bir yapı kullanır.Model içindeki önem derecesi kavramı, ResNeXt'in temelini oluşturur. Bu kavram, ağın içindeki farklı parçaların sayısını ifade eder. ResNeXt, bu kavramı kullanarak, daha fazla çeşitlilik ve esneklik sağlayan daha büyük ve paralel parçalarla güçlendirilmiş bir yapı sunar [6].

Bu çalışmada ResNeXt-50 mimarisi, geliştirilen siamese network için omurga olarak kullanılmıştır. ResNeXt mimarisi modifikasyonlar ile iki görüntü girdi alacak hale getirilmiştir. Yapılan modifikasyonlar sonucunda imza görüntüsü, frekans spektrumu görüntüsü ve HOG görüntüsü 3 ayrı konvolüsyon katmanından geçirilerek öznitelik vektörleri haline getirilmiş, bu öznitelik vektörleri birleştirilerek sonraki konvolüsyon katmanları beslenmiştir. Konvolüsyon katmanlarından sonra gelen sınıflayıcı doğrusal katmanlar çıkartılıp, problemimize uygun şekilde iki görüntü girdi alan ResNeXt mimarisinin ürettiği öznitelik vektörlerini birleştirerek sınıflandıran bir doğrusal katman eklenmiştir.

TABLO II: Önerilen Modelin Başarım Değerleri

Veri Kümesi	Mimariler	Doğruluk Oranı	FAR	FFR
CEDAR	2-Channel-2-Logit	100	-	-
	SigNet	100	0	0
	LBP ve ULBP	-	-	-
	SigNet	100	0	0
	Önerilen Model Siamese ResNeXt-50	100	0	0
Bengali	2-Channel-2-Logit	88.08	10.44	9.37
	SigNet	86.11	13.89	13.89
	LBP ve ULBP	66.18	33.82	33.82
	SigNet	86.11	13.89	13.89
	Önerilen Model Siamese ResNeXt-50	87.4	12.8	5.7
Hindi	2-Channel-2-Logit	86.66	-	-
	SigNet	84.64	15.36	15.36
	LBP ve ULBP	66.18	-	-
	SigNet	84.64	15.36	15.36
	Önerilen Model Siamese ResNeXt-50	87.18	13.14	6.12

IV. Sonuçlar ve Tartışmalar

Bu çalışmada, literatürde bulunan imza doğrulama modellerine bir katkıda bulunarak bu sistemleri geliştirmeyi amaçlayan yeni bir derin öğrenme modeli sunulmuştur. Önerilen model, görüntülerin yanı sıra frekans spektrumu ve HOG gibi ek özelliklerden de yararlanarak imza doğrulamada yüksek doğruluk elde etmeyi hedeflemektedir.

Siamese ResNeXt-50 modeli, CEDAR, BHSig260-Bengali ve BHSig260-Hindi veri kümeleri üzerinde kapsamlı bir şekilde değerlendirilmiştir. Elde edilen sonuçlar, önerilen modelin diğer yöntemlere kıyasla önemli ölçüde daha yüksek doğruluk elde ettiğini göstermiştir. Tablo 2, farklı mimarilerin veri kümeleri üzerindeki başarımlarının karşılaştırmasını göstermektedir. BHSig260-Hindi veri kümesinde Siamese ResNeXt-50 modeli yüzde 87.18 doğruluk elde ederek, 2-Channel-2-Logit, SigNet, LBP ve ULBP modellerini geride bırakmıştır.

SigNet, çevrimdışı imza doğrulama için Siyami ağı temelli bir derin öğrenme modelidir ve ResNeXt modelinden farklı olarak bağımsız özellik öğrenimini kullanır. Bu yöntem, üretilen özelliklere dayanmaz, bunun yerine verilerden yazar bağımsız bir senaryoda öğrenir [7]. SigNet'in önerilen modele rakip olması, gelecekteki ResNeXt-50 mimarisi için önemli bir referans noktasıdır.

Yanlış Kabul Oranı (False Acceptance Rate - FAR), bir imza doğrulama sisteminde, sistemin sahte bir imzayı yetkili bir kullanıcının imzası olarak kabul etmesi durumudur. Düşük FAR değeri, sistemin sahte imzaları daha doğru bir şekilde tespit ettiğini ve hatalı kabul etme olasılığının daha düşük olduğunu gösterir. Özellikle dolandırıcılık ve kimlik hırsızlığı gibi risklerin yüksek olduğu alanlar için önemli bir durumdur.

Yanlış Reddetme Oranı (False Rejection Rate - FRR), bir imza doğrulama sisteminde, sistemin yetkili bir kullanıcının imzasını sahte olarak reddetmesi durumudur. Düşük FAR değeri, sistemin yetkili kullanıcıları daha doğru bir şekilde tanıdığını ve hatalı reddetme olasılığının daha düşük olduğunu gösterir. Bu durum, özellikle yüksek güvenlik gerektiren sistemler için oldukça önemlidir. Örneğin, bankacılık işlemleri veya yasal işlemler sırasında imza doğrulama sistemlerinin düşük FRR değerine sahip olması hayati önem taşımaktadır.

Authorized licensed use limited to: REVA UNIVERSITY. Downloaded on October 09,2026 at 06:57:50 UTC from IEEE Xplore. Restrictions apply.

Tablo 2'de de görüldüğü üzere,Siamese ResNeXt-50 her üç veri kümesinde de en düşük FAR ve FRR değerlerine sahip modeldir. Bu durum, modelin imzaları daha doğru bir şekilde ayırt edebildiğini ve yanlış kabul veya reddetme olasılığının daha düşük olduğunu göstermektedir.

Özetle Siamese ResNeXt-50 modeli, lüteratürde bulunan diğer modellere kıyasla daha özgün bir mimariye sahip olması ve yüksek doğruluk oranı ile literatürde yeni bir potansiyeline sahiptir. Gelecek çalışmamızda, Siamese ResNeXt-50 modelinin daha yüksek doğruluk oranlarına ulaşabilmesine yönelik model mimarsinin geliştirilmesi için yollar aranacaktır.

KAYNAKLAR

[1] Hafemann, Luiz G., Robert Sabourin, and Luiz S. Oliveira. "Learning features for offline handwritten signature verification using deep convolutional neural networks." Pattern Recognition 70 (2017): 163-176.

[2] Pal, Srikanta, et al. "Performance of an off-line signature verification method based on texture features on a large indic-script signature dataset." 2016 12th IAPR workshop on document analysis systems (DAS). IEEE, 2016.

[3] Li, Chuang, et al. "DeepHSV: User-independent offline signature verification using two-channel CNN." 2019 International Conference on Document Analysis and Recognition (ICDAR). IEEE, 2019.

[4] Pal, Srikanta, et al. "Performance of an off-line signature verification method based on texture features on a large indic-script signature dataset." 2016 12th IAPR workshop on document analysis systems (DAS). IEEE, 2016.

[5] Srinivasan, Harish, Sargur N. Srihari, and Matthew J. Beal. "Machine learning for signature verification." Computer Vision, Graphics and Image Processing: 5th Indian Conference, ICVGIP 2006, Madurai, India, December 13-16, 2006. Proceedings. Springer Berlin Heidelberg, 2006.

[6] Xie, Saining, et al. "Aggregated residual transformations for deep neural networks." Proceedings of the IEEE conference on computer vision and pattern recognition. 2017.

[7] Dey, S., Dutta, A., Toledo, J. I., Ghosh, S. K., Lladós, J., & Pal, U. (2017). Signet: Convolutional siamese network for writer independent offline signature verification. *arXiv preprint arXiv:1707.02131*.

Authorized licensed use limited to: REVA UNIVERSITY. Downloaded on October 09,2026 at 06:57:50 UTC from IEEE Xplore. Restrictions apply.